CLUSTERING EN R

BIOINFORMÁTICA

- EPD 5 -

Luis Carmona Berdugo

Problema 1

A partir del conjunto de datos de microarrays de NCBI que puede descargar de “https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE227018”, realice un análisis completo de Clustering y Biclustering. Ejecute múltiples métodos de Clustering y Biclustering e indique las diferencias que existen entre ellos. Debe adjuntar todos los ficheros utilizados en un .zip (datasets, scripts, análisis y explicación...etc).

Voy a usar el microarray “GSE227018_norm_rma” de la serie “GSE227018”, el cual estudia el papel de los exosomas derivados del sarcoma en su desarrollo y metástasis. Se centra en cómo la secreción aumentada de exosomas y la selección específica de miARN pueden contribuir a la patogénesis del sarcoma.

En primer lugar instalaré los paquetes necesarios y leeré los datos usando read.table(). Tras esto transformaré los datos con un preprocesamiento filtrando solo ceros y aplicando normalización logarítmica.

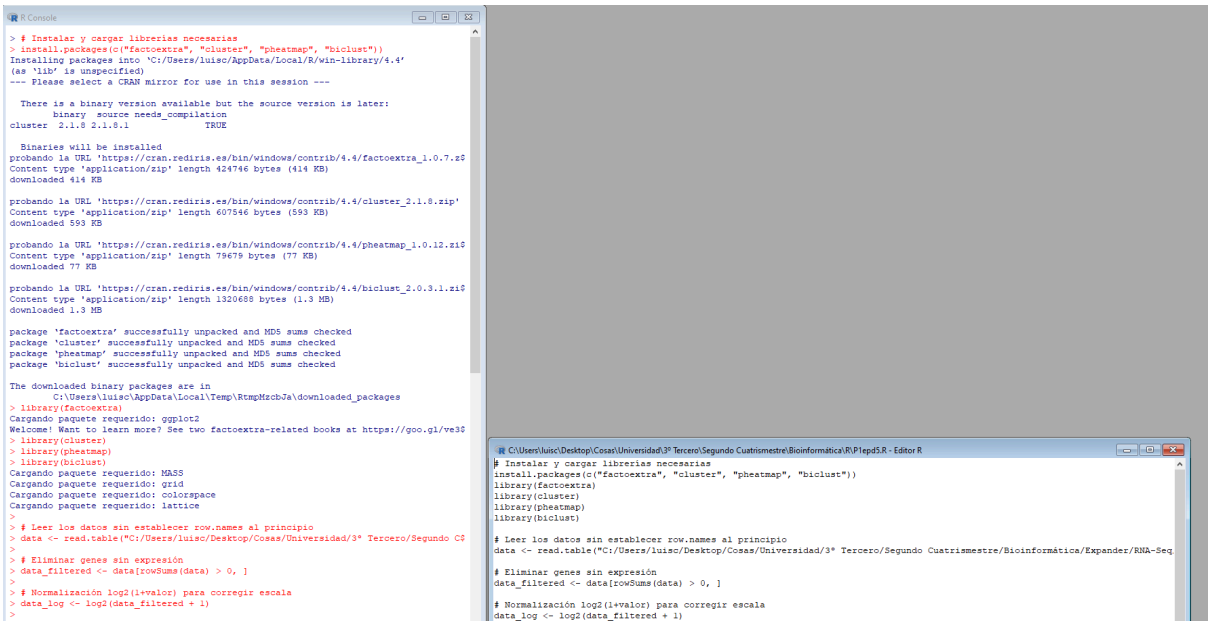

Para que R realice los análisis correspondientes de maneras más rápida, evitando que la aplicación se cuelgue, usaremos una muestra del datasets con una muestra aleatoria de 500 genes. Además podemos ver gráfico del número óptimo de clusters.

```
>
> # Para reproducibilidad
> set.seed(123)
>
> # Seleccionar una muestra aleatoria de 500 genes (ajusta según sea necesario)
> sample_data <- data_log[sample(nrow(data_log), 500), ]
>
> # Aplicar método "Gap Statistic" en la muestra
> fviz_nbclust(sample_data, kmeans, method = "gap_stat")
Clustering k = 1,2,..., K.max (= 10): .. done
Bootstrapping, b = 1,2,..., B (= 100)  [one "." per sample]:
.................................................. 50
.................................................. 100
```

```
# Para reproducibilidad
set.seed(123)

# Seleccionar una muestra aleatoria de 500 genes (ajusta según sea necesario)
sample_data <- data_log[sample(nrow(data_log), 500), ]

# Aplicar método "Gap Statistic" en la muestra
fviz_nbclust(sample_data, kmeans, method = "gap_stat")

# Aplicar k-means con k = 4 (como ejemplo)
set.seed(123)
clusters_km <- kmeans(sample_data, centers=4, nstart=25)
```

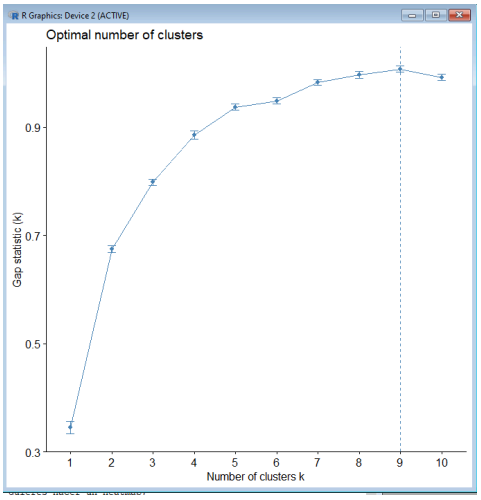

Tras esto comenzaré realizando los métodos de clustering, en primer lugar K-Means que divide los datos en k grupos minimizando la varianza en cada cluster. Podemos generar también el gráfico correspondiente.

```
>
> # Aplicar k-means con k = 4 (como ejemplo)
> set.seed(123)
> clusters_km <- kmeans(sample_data, centers=4, nstart=25)
>
> # Visualizar clustering
> fviz_cluster(clusters_km, data = sample_data)
>
```

```
# Aplicar k-means con k = 4 (como ejemplo)
set.seed(123)
clusters_km <- kmeans(sample_data, centers=4, nstart=25)

# Visualizar clustering
fviz_cluster(clusters_km, data = sample_data)
```

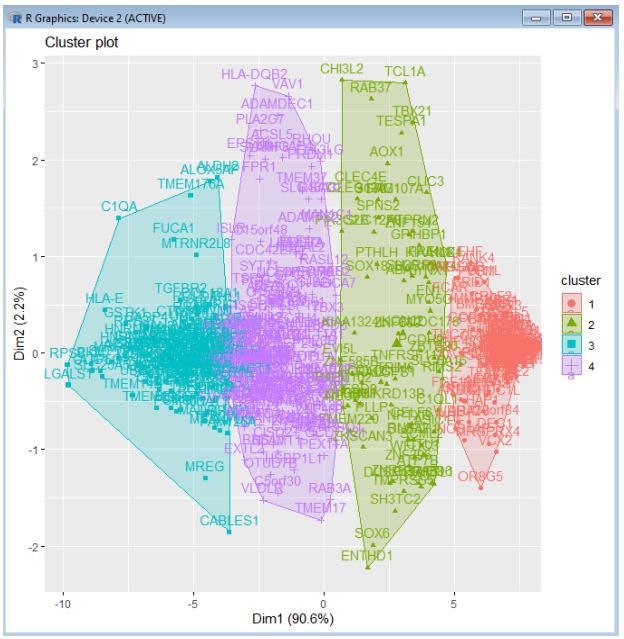

También realizaré clustering PAM, similar a K-Means pero más robusto a valores atípicos. De nuevo observamos el gráfico.

```
> # Calcular matriz de distancias euclidianas
> dist_matrix <- dist(sample_data, method = "euclidean")
>
> # Aplicar clustering PAM con 4 clusters
> clusters_pam <- pam(dist_matrix, k = 4)
>
> # Visualizar los clusters PAM
> fviz_cluster(list(data = sample_data, cluster = clusters_pam$clustering))
>
```

```
# Calcular matriz de distancias euclidianas
dist_matrix <- dist(sample_data, method = "euclidean")

# Aplicar clustering PAM con 4 clusters
clusters_pam <- pam(dist_matrix, k = 4)

# Visualizar los clusters PAM
fviz_cluster(list(data = sample_data, cluster = clusters_pam$clustering))
```

Finalmente realizaré el método de biclustering Spectral, el cual usa descomposición en valores singulares para detectar subestructuras.

```
> # Convertir a matriz numérica
> sample_data_matrix <- as.matrix(sample_data)
>
> # Aplicar biclustering Spectral
> biclusters_spectral <- biclust(sample_data_matrix, method = BCSpectral())
Aviso:
In spectral(x, normalization, numberOfEigenvalues, minr, minc, withinVar) :
  No biclusters found
>
> # Visualizar los biclusters (esta parte debe ser adaptada si quieres hacer un hea$
> pheatmap(sample_data_matrix)
>
```

```
# Convertir a matriz numérica
sample_data_matrix <- as.matrix(sample_data)

# Aplicar biclustering Spectral
biclusters_spectral <- biclust(sample_data_matrix, method = BCSpectral())

# Visualizar los biclusters (esta parte debe ser adaptada si quieres hacer un heatmap)
pheatmap(sample_data_matrix)
```

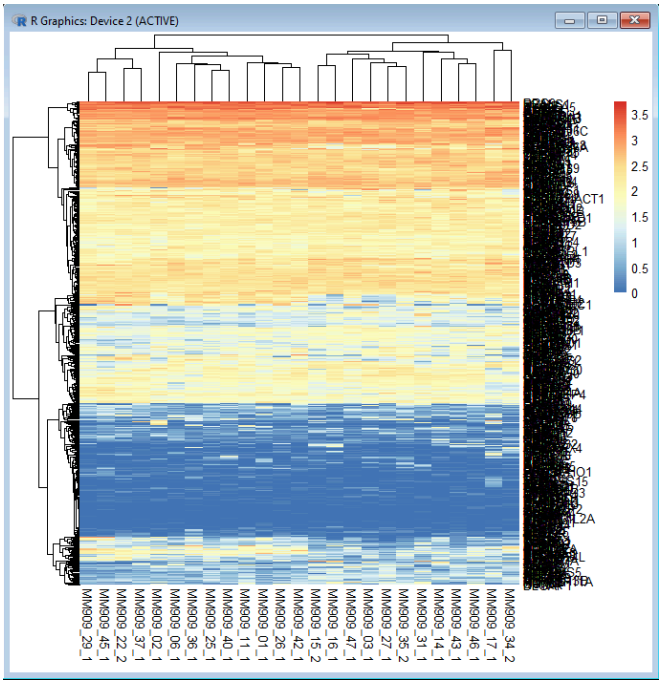

En conclusión la diferencia entre clustering y biclustering es que clustering agrupa los genes según su similitud, mientras que biclustering encuentra subgrupos de genes y condiciones. Además, podemos concluir que K-Means y PAM son útiles para datos grandes, mientras que Spectral es ideal para detectar estructuras ocultas en los datos.

Problema 2

A partir del conjunto de datos de RNA-Seq de NCBI que puede descargar de "https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE261149", realice un análisis completo de Clustering y Biclustering. Ejecute múltiples métodos de Clustering y Biclustering e indique las diferencias que existen entre ellos. Debe adjuntar todos los ficheros utilizados en un .zip (datasets, scripts, análisis y explicación...etc).

Voy a usar el conjunto de datos "GSE261149_gene_count_matrix" de la serie "GSE261149", el cual analiza los niveles de expresión de ARNm en sinoviocitos fibroblastoides (FLS) de pacientes con artritis reumatoide (AR) bajo diferentes condiciones: sin tratamiento, con ginsenósido CK o con dexametasona.

En primer lugar instalaré los paquetes necesarios y leeré los datos usando read.table(). Tras esto transformaré los datos con un preprocesamiento filtrando solo ceros y aplicando normalización logarítmica.

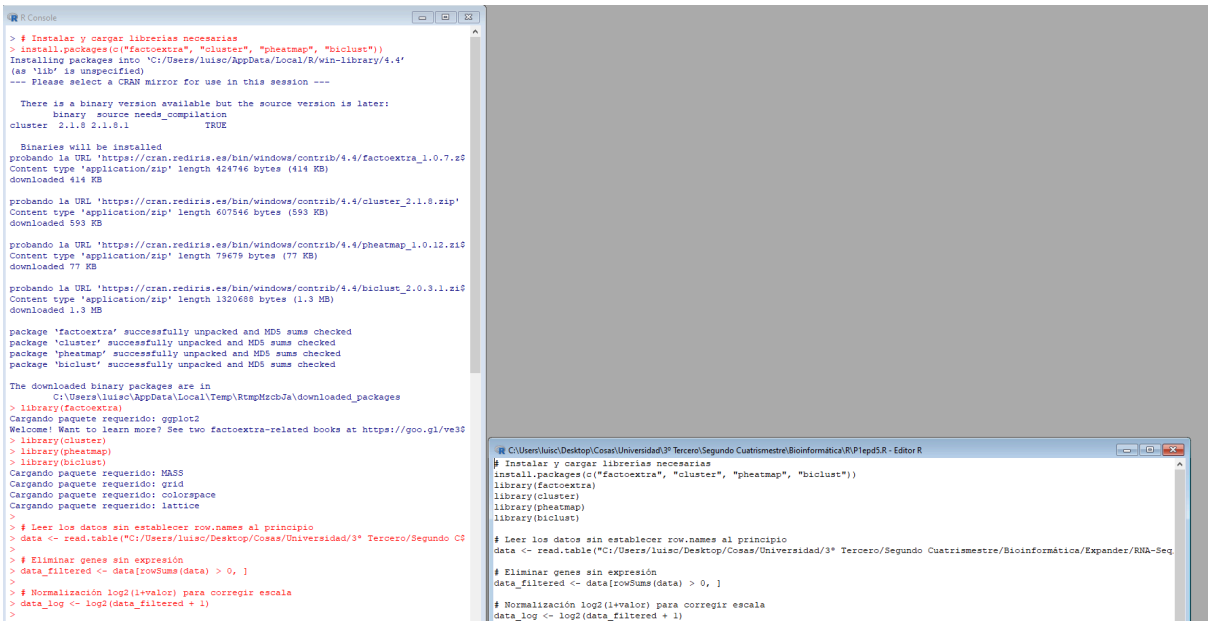

Para que R realice los análisis correspondientes de maneras más rápida, evitando que la aplicación se cuelgue, usaremos una muestra del datasets con una muestra aleatoria de 500 genes. Además podemos ver gráfico del número óptimo de clusters.

```
>
> # Para reproducibilidad
> set.seed(123)
>
> # Seleccionar una muestra aleatoria de 500 genes (ajusta según sea necesario)
> sample_data <- data_log[sample(nrow(data_log), 500), ]
>
> # Aplicar método "Gap Statistic" en la muestra
> fviz_nbclust(sample_data, kmeans, method = "gap_stat")
Clustering k = 1,2,..., K.max (= 10): .. done
Bootstrapping, b = 1,2,..., B (= 100)  [one "." per sample]:
.................................................. 50
.................................................. 100
```

```
# Para reproducibilidad
set.seed(123)

# Seleccionar una muestra aleatoria de 500 genes (ajusta según sea necesario)
sample_data <- data_log[sample(nrow(data_log), 500), ]

# Aplicar método "Gap Statistic" en la muestra
fviz_nbclust(sample_data, kmeans, method = "gap_stat")

# Aplicar k-means con k = 4 (como ejemplo)
set.seed(123)
clusters_km <- kmeans(sample_data, centers=4, nstart=25)
```

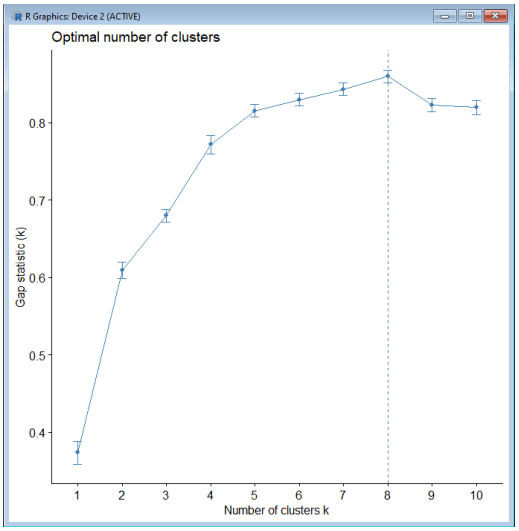

Tras esto comenzaré realizando los métodos de clustering, en primer lugar K-Means que divide los datos en k grupos minimizando la varianza en cada cluster. Podemos generar también el gráfico correspondiente.

```
>
> # Aplicar k-means con k = 4 (como ejemplo)
> set.seed(123)
> clusters_km <- kmeans(sample_data, centers=4, nstart=25)
>
> # Visualizar clustering
> fviz_cluster(clusters_km, data = sample_data)
>
```

```
# Aplicar k-means con k = 4 (como ejemplo)
set.seed(123)
clusters_km <- kmeans(sample_data, centers=4, nstart=25)

# Visualizar clustering
fviz_cluster(clusters_km, data = sample_data)
```

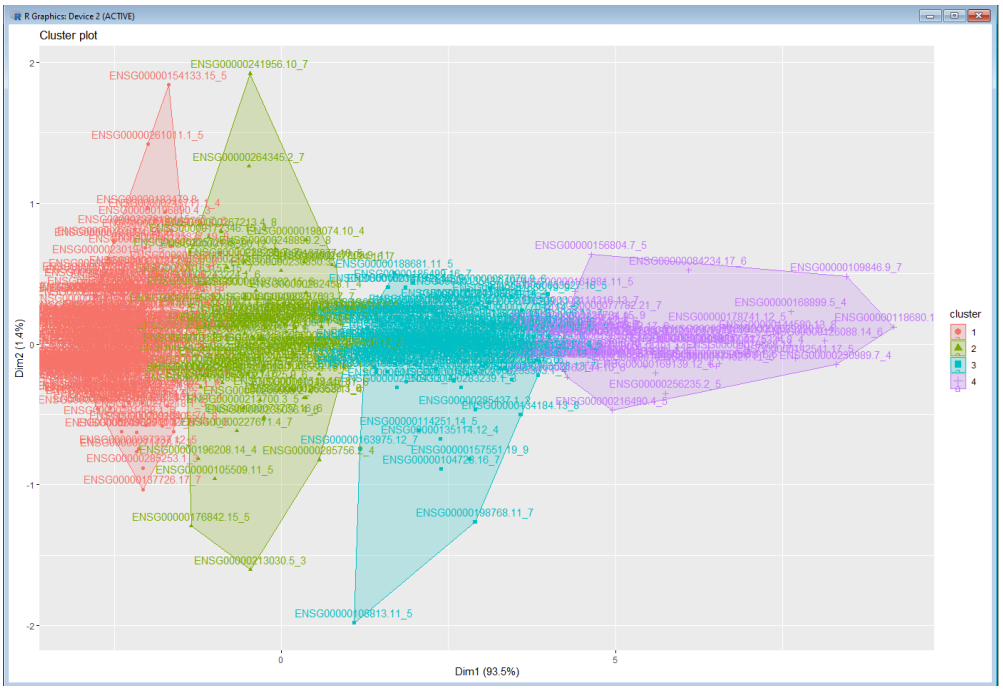

También realizaré clustering PAM, similar a K-Means pero más robusto a valores atípicos. De nuevo observamos el gráfico.

```
> # Calcular matriz de distancias euclidianas
> dist_matrix <- dist(sample_data, method = "euclidean")
>
> # Aplicar clustering PAM con 4 clusters
> clusters_pam <- pam(dist_matrix, k = 4)
>
> # Visualizar los clusters PAM
> fviz_cluster(list(data = sample_data, cluster = clusters_pam$clustering))
>
```

```
# Calcular matriz de distancias euclidianas
dist_matrix <- dist(sample_data, method = "euclidean")

# Aplicar clustering PAM con 4 clusters
clusters_pam <- pam(dist_matrix, k = 4)

# Visualizar los clusters PAM
fviz_cluster(list(data = sample_data, cluster = clusters_pam$clustering))
```

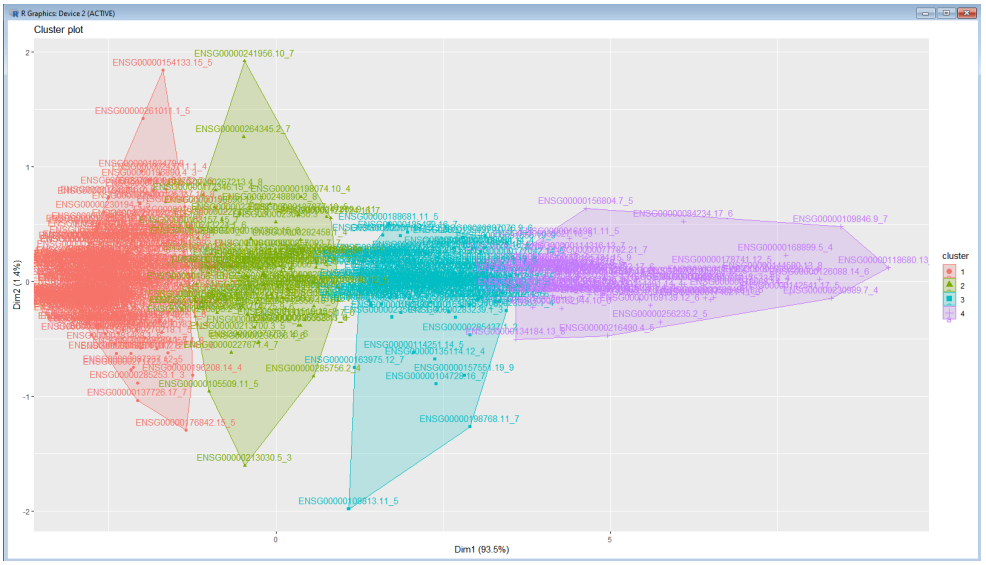

Finalmente realizaré el método de biclustering Spectral, el cual usa descomposición en valores singulares para detectar subestructuras.

```
> # Convertir a matriz numérica
> sample_data_matrix <- as.matrix(sample_data)
>
> # Aplicar biclustering Spectral
> biclusters_spectral <- biclust(sample_data_matrix, method = BCSpectral())
Aviso:
In spectral(x, normalization, numberOfEigenvalues, minr, minc, withinVar) :
  No biclusters found
>
> # Visualizar los biclusters (esta parte debe ser adaptada si quieres hacer un hea$
> pheatmap(sample_data_matrix)
>
```

```
# Convertir a matriz numérica
sample_data_matrix <- as.matrix(sample_data)

# Aplicar biclustering Spectral
biclusters_spectral <- biclust(sample_data_matrix, method = BCSpectral())

# Visualizar los biclusters (esta parte debe ser adaptada si quieres hacer un heatmap)
pheatmap(sample_data_matrix)
```

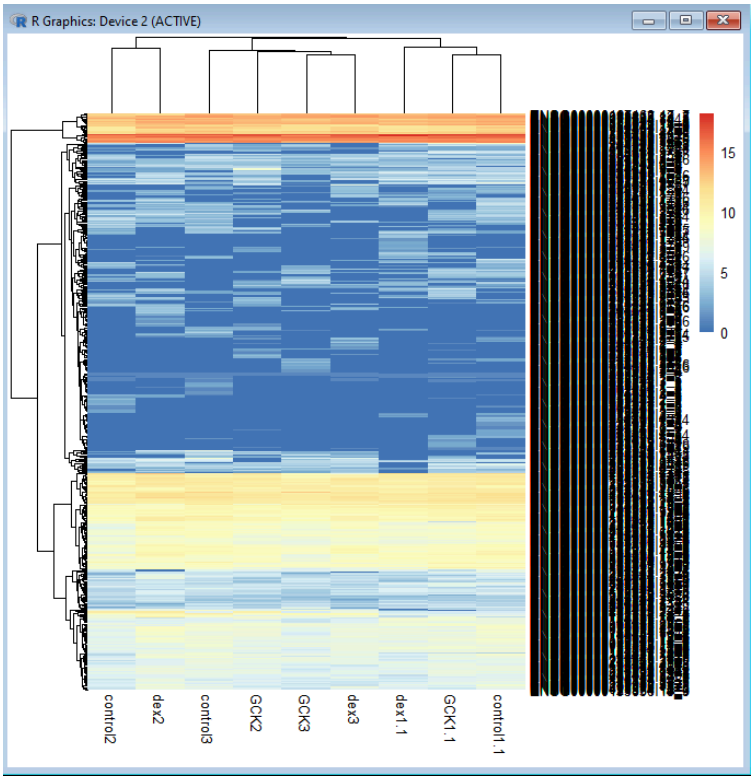

En conclusión la diferencia entre clustering y biclustering es que clustering agrupa los genes según su similitud, mientras que biclustering encuentra subgrupos de genes y condiciones. Además, podemos concluir que K-Means y PAM son útiles para datos grandes, mientras que Spectral es ideal para detectar estructuras ocultas en los datos.