GENERACIÓN DE REDES GÉNICAS, VISUALIZACIÓN Y TRATAMIENTO EN R

BIOINFORMÁTICA

- EPD 8 -

Luis Carmona Berdugo

Problema 1

Cree una red de co-expresión con al menos tres medidas usando alguno de los datasets que descargó del NCBI. Realice el
análisis de los resultados utilizando 2 de los métodos de correlación de Pearson, de Spearman o de Kendall. Compárelos.

Voy a usar el microarray “GSE227018_series_matrix” de la serie “GSE227018”, el cual se enfoca en el estudio de exosomas derivados del sarcoma y su papel en el desarrollo y la metástasis.

En primer lugar comenzaré almacenando la matriz de expresión del dataset en data_text, además de visualizar las primeras líneas de la matriz para comprobar su correcta lectura.

```
R Console
> ## 1. Definir la ruta completa al archivo
> file_path <- "C:/Users/luisc/Desktop/Nueva carpeta/GSE227018_series_matrix.txt"
>
> # Leer todas las lineas del archivo
> lines <- readLines(file_path)
>
> # Identificar las lineas donde comienza y termina la tabla de expresión
> start_line <- grep("!series_matrix_table_begin", lines)
> end_line   <- grep("!series_matrix_table_end", lines)
>
> # Extraer únicamente el bloque que contiene la matriz de expresión
> data_text <- lines[(start_line + 1):(end_line - 1)]
>
> # Convertir el bloque de texto en una tabla de datos
> exp_data <- read.table(text = data_text, header = TRUE, sep = "\t", quote = ""$
>
> # Visualizar las primeras filas para confirmar que se ha leido correctamente
> head(exp_data)
      "ID_REF" "GSM7090073" "GSM7090074" "GSM7090075" "GSM7090076"
1     "14q0_st"         0.59         0.42         0.21         0.64
2   "14qI-1_st"         0.55         0.55         0.48         0.55
3 "14qI-1_x_st"         0.32         0.32         0.26         0.32
4   "14qI-2_st"        -0.06         0.11         0.11         0.22
5 "14qI-3_x_st"         1.03         0.92         0.51         0.88
6   "14qI-4_st"         0.59         0.58         0.32         0.32
  "GSM7090077" "GSM7090078" "GSM7090079" "GSM7090080" "GSM7090081"
1         0.59         0.22         0.98         0.59         0.64
2         0.85         0.55         0.31         0.52         0.69
3         0.32         0.21         0.09         0.16         0.44
4        -0.12        -0.15         0.44         0.27         0.11
5         0.88         0.80         0.82         1.80         0.88
6         0.59         0.59         0.92         0.30         0.84
>
>
```

```
C:\Users\luisc\Desktop\Nueva carpeta\EPD8_P1.R - Editor R
## 1. Definir la ruta completa al archivo
file_path <- "C:/Users/luisc/Desktop/Nueva carpeta/GSE227018_series_matrix.txt"

# Leer todas las lineas del archivo
lines <- readLines(file_path)

# Identificar las lineas donde comienza y termina la tabla de expresión
start_line <- grep("!series_matrix_table_begin", lines)
end_line   <- grep("!series_matrix_table_end", lines)

# Extraer únicamente el bloque que contiene la matriz de expresión
data_text <- lines[(start_line + 1):(end_line - 1)]

# Convertir el bloque de texto en una tabla de datos
exp_data <- read.table(text = data_text, header = TRUE, sep = "\t", quote = "",

# Visualizar las primeras filas para confirmar que se ha leido correctamente
head(exp_data)
```

Tras esto preparamos la matriz numérica y calculamos correlaciones, en mi caso voy a usar las correlaciones de Pearson y la de Spearman.

```
>
> ## 2. Preparar la matriz numérica de expresión y calcular correlaciones
>
> # Separamos los identificadores y la matriz de expresión (convirtiéndola a numérica)
> genes <- exp_data[, 1]  # Identificadores de genes
> expr_matrix <- as.matrix(exp_data[, -1])
> mode(expr_matrix) <- "numeric"  # Forzamos a numérico, en caso de que sea necesario
>
> # Para calcular la correlación entre genes (cada gen representado por su perfil de expresión en las muestras),
> # se debe transponer la matriz: filas=genes, columnas=muestras -> t(expr_matrix) da filas = muestras.
> # Así cor(t(expr_matrix)) genera la correlación entre genes.
> cor_pearson <- cor(t(expr_matrix), method = "pearson")
> cor_spearman <- cor(t(expr_matrix), method = "spearman")
```

```
# Separamos los identificadores y la matriz de expresión (convirtiéndola a numé
genes <- exp_data[, 1]  # Identificadores de genes
expr_matrix <- as.matrix(exp_data[, -1])
mode(expr_matrix) <- "numeric"  # Forzamos a numérico, en caso de que sea neces

# Para calcular la correlación entre genes (cada gen representado por su perfil
# se debe transponer la matriz: filas=genes, columnas=muestras -> t(expr_matri
# Así cor(t(expr_matrix)) genera la correlación entre genes.
cor_pearson <- cor(t(expr_matrix), method = "pearson")
cor_spearman <- cor(t(expr_matrix), method = "spearman")
```

Después procedemos a hacer la umbralización de las correlaciones y la construcción de matrices de adyacencia

```
>
> ## 3. Umbralización de las correlaciones y construcción de matrices de adyacencia
>
> # Definir un umbral de interés. En este ejemplo, usamos 0.8.
> threshold <- 0.8
>
> # Convertir las matrices de correlación en matrices de adyacencia.
> # Se toman valores absolutos para considerar tanto correlaciones positivas como negativas.
> adj_pearson <- (abs(cor_pearson) >= threshold) * 1
> diag(adj_pearson) <- 0   # Eliminar autorrelaciones (valor 1 en la diagonal)
>
> adj_spearman <- (abs(cor_spearman) >= threshold) * 1
> diag(adj_spearman) <- 0
```

```
## 3. Umbralización de las correlaciones y construcción de matrices de adyacenc

# Definir un umbral de interés. En este ejemplo, usamos 0.8.
threshold <- 0.8

# Convertir las matrices de correlación en matrices de adyacencia.
# Se toman valores absolutos para considerar tanto correlaciones positivas como
adj_pearson <- (abs(cor_pearson) >= threshold) * 1
diag(adj_pearson) <- 0   # Eliminar autorrelaciones (valor 1 en la diagonal)

adj_spearman <- (abs(cor_spearman) >= threshold) * 1
diag(adj_spearman) <- 0
```

Por otro lado, pasaremos a crear las redes de co-expresión, en mi caso lo he realizado usando igraph.

```
>
> ## 4. Creación de las redes de co-expresión utilizando igraph
>
> # Instalar y cargar el paquete si aún no lo tienes:
> # install.packages("igraph")
> library(igraph)
>
> # Generar grafos a partir de las matrices de adyacencia.
> # El parámetro mode="undirected" es adecuado ya que la correlación es simétrica.
> g_pearson <- graph_from_adjacency_matrix(adj_pearson, mode = "undirected", weighted = TRUE, diag = FALSE)
> g_spearman <- graph_from_adjacency_matrix(adj_spearman, mode = "undirected", weighted = TRUE, diag = FALSE)
>
> # Asignar los nombres de los nodos usando los identificadores de genes
> V(g_pearson)$name <- genes
> V(g_spearman)$name <- genes
>
```

```
## 4. Creación de las redes de co-expresión utilizando igraph

# Instalar y cargar el paquete si aún no lo tienes:
# install.packages("igraph")
library(igraph)

# Generar grafos a partir de las matrices de adyacencia.
# El parámetro mode="undirected" es adecuado ya que la correlación es simétrica
g_pearson <- graph_from_adjacency_matrix(adj_pearson, mode = "undirected", weig
g_spearman <- graph_from_adjacency_matrix(adj_spearman, mode = "undirected", we

# Asignar los nombres de los nodos usando los identificadores de genes
V(g_pearson)$name <- genes
V(g_spearman)$name <- genes
```

Finalmente pasaremos a hacer un análisis y una comparación entre las redes.

```
> # Resumen básico de los grafos
> cat("Red basada en Pearson:\n")
Red basada en Pearson:
> print(summary(g_pearson))
IGRAPH 7209aac UNW- 147 590 --
+ attr: name (v/c), weight (e/n)
IGRAPH 7209aac UNW- 147 590 --
+ attr: name (v/c), weight (e/n)
+ edges from 7209aac (vertex names):
 [1] "14q0_st"    --"14qII-8_st"    "14q0_st"    --"14qII-8_x_st"
 [3] "14qI-1_x_st"--"ACA16_st"      "14qI-2_st"  --"14qII-10_st"
 [5] "14qI-2_st"  --"14qII-8_st"    "14qI-2_st"  --"ACA16_x_st"
 [7] "14qI-2_st"  --"ACA20_st"      "14qI-2_st"  --"ACA37_st"
 [9] "14qI-2_st"  --"ACA37_x_st"    "14qI-3_x_st"--"14qII-21_x_st"
[11] "14qI-4_st"  --"14qI-8_x_st"   "14qI-4_st"  --"ACA32_x_st"
[13] "14qI-4_x_st"--"14qII-5_x_st"  "14qI-5_st"  --"ACA25_st"
[15] "14qI-6_st"  --"14qII-22_x_st" "14qI-6_st"  --"ACA11_st"
+ ... omitted several edges
> cat("\nRed basada en Spearman:\n")

Red basada en Spearman:
> print(summary(g_spearman))
IGRAPH 720d8e7 UNW- 147 483 --
+ attr: name (v/c), weight (e/n)
IGRAPH 720d8e7 UNW- 147 483 --
+ attr: name (v/c), weight (e/n)
+ edges from 720d8e7 (vertex names):
 [1] "14q0_st"    --"14qII-22_x_st" "14qI-1_st"  --"14qI-1_x_st"
 [3] "14qI-1_st"  --"ACA20_st"      "14qI-2_st"  --"14qII-8_st"
 [5] "14qI-2_st"  --"14qII-8_x_st"  "14qI-2_st"  --"ACA20_st"
 [7] "14qI-2_st"  --"ACA37_st"      "14qI-2_st"  --"ACA37_x_st"
 [9] "14qI-4_st"  --"14qI-8_x_st"   "14qI-4_st"  --"14qII-3_st"
[11] "14qI-4_st"  --"ACA24_x_st"    "14qI-4_st"  --"ACA32_x_st"
[13] "14qI-4_x_st"--"14qII-5_x_st"  "14qI-5_st"  --"ACA25_st"
[15] "14qI-6_st"  --"ACA36B_s_st"   "14qI-7_st"  --"14qII-30_st"
+ ... omitted several edges
>
```

```
C:\Users\luisc\Desktop\Nueva carpeta\EPD8_P1.R - Editor R

# Resumen básico de los grafos
cat("Red basada en Pearson:\n")
print(summary(g_pearson))
cat("\nRed basada en Spearman:\n")
print(summary(g_spearman))

# Número de nodos y enlaces:
cat("\nNodos y enlaces (Pearson):", vcount(g_pearson), "nodos,", ecount(g_pears
cat("Nodos y enlaces (Spearman):", vcount(g_spearman), "nodos,", ecount(g_spear

# Distribución de grados
deg_pearson <- degree(g_pearson)
deg_spearman <- degree(g_spearman)

cat("\nGrado promedio (Pearson):", mean(deg_pearson), "\n")
cat("Grado promedio (Spearman):", mean(deg_spearman), "\n")

# Coeficiente de clustering promedio (indicador de cohesión local)
clust_pearson <- transitivity(g_pearson, type = "average")
clust_spearman <- transitivity(g_spearman, type = "average")

cat("\nCoeficiente de clustering (Pearson):", clust_pearson, "\n")
cat("Coeficiente de clustering (Spearman):", clust_spearman, "\n")
```

He realizado un análisis de estas 3 medidas:

- Nodos y enlaces:Ambas redes tienen 147 nodos; Pearson muestra 590 enlaces y Spearman 483, lo que indica que Pearson detecta más interacciones lineales, mientras que Spearman resalta relaciones más robustas y selectivas. Esto sugiere que Pearson ofrece mayor densidad, pero con riesgo de incluir ruido, mientras que Spearman filtra conexiones menos confiables.

```
>
> # Número de nodos y enlaces:
> cat("\nNodos y enlaces (Pearson):", vcount(g_pearson), "nodos,", ecount(g_pearson), "enlaces\n")

Nodos y enlaces (Pearson): 147 nodos, 590 enlaces
> cat("Nodos y enlaces (Spearman):", vcount(g_spearman), "nodos,", ecount(g_spearman), "enlaces\n")
Nodos y enlaces (Spearman): 147 nodos, 483 enlaces
>
```

- Distribución de grados: Ambas redes muestran diferencias en su distribución de grados. Pearson, con un grado promedio de 8.03, es más densa y presenta numerosos hubs aunque puede incluir más ruido. En contraste, Spearman, con 6.57 de grado promedio, filtra conexiones, resaltando interacciones robustas y selectivas, además facilitando la identificación de módulos funcionales.

```
>
> # Distribución de grados
> deg_pearson <- degree(g_pearson)
> deg_spearman <- degree(g_spearman)
>
> cat("\nGrado promedio (Pearson):", mean(deg_pearson), "\n")

Grado promedio (Pearson): 8.027211
> cat("Grado promedio (Spearman):", mean(deg_spearman), "\n")
Grado promedio (Spearman): 6.571429
```

- Coeficiente de clustering: El coeficiente de clustering revela diferencias en la cohesión local de cada red. La red Pearson (0.6175) muestra agrupamientos densos y comunidades bien definidas entre genes. En contraste, la red Spearman (0.4802) presenta menor cohesión local y conexiones más dispersas, sugiriendo interacciones menos intensas y una estructura global más moderada.

```
> # Coeficiente de clustering promedio (indicador de cohesión local)
> clust_pearson <- transitivity(g_pearson, type = "average")
> clust_spearman <- transitivity(g_spearman, type = "average")
>
> cat("\nCoeficiente de clustering (Pearson):", clust_pearson, "\n")

Coeficiente de clustering (Pearson): 0.6175352
> cat("Coeficiente de clustering (Spearman):", clust_spearman, "\n")
Coeficiente de clustering (Spearman): 0.4802079
>
```

Para finalizar también he querido mostrar las redes de cada correlación.

Pearson

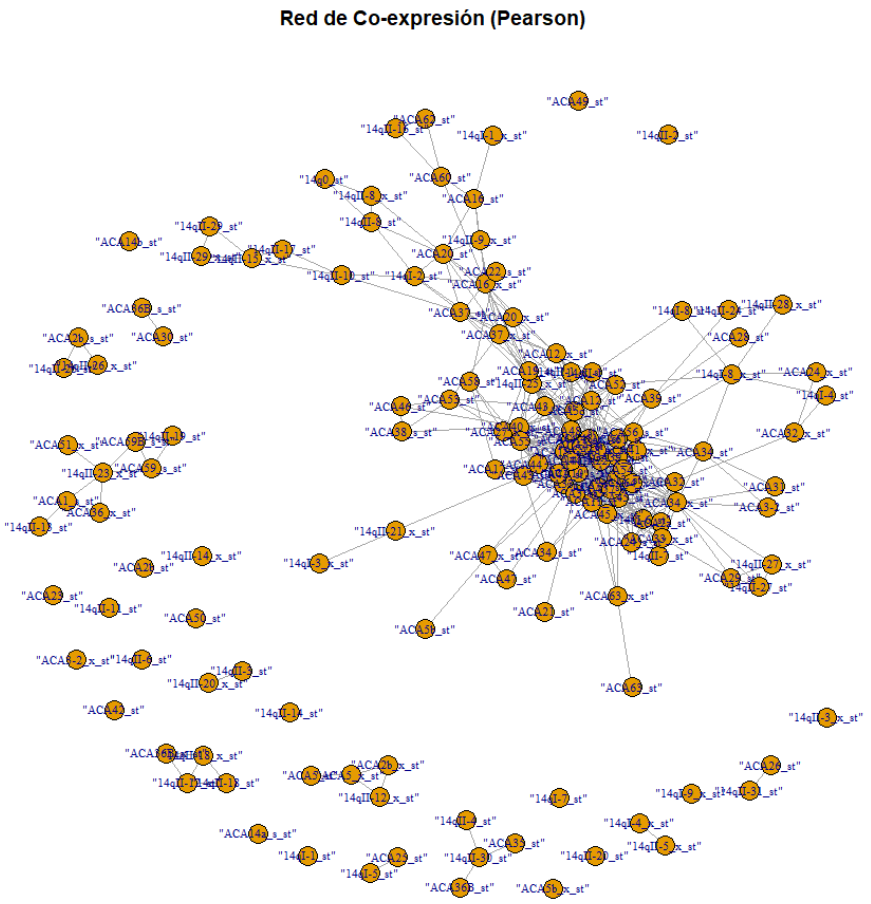
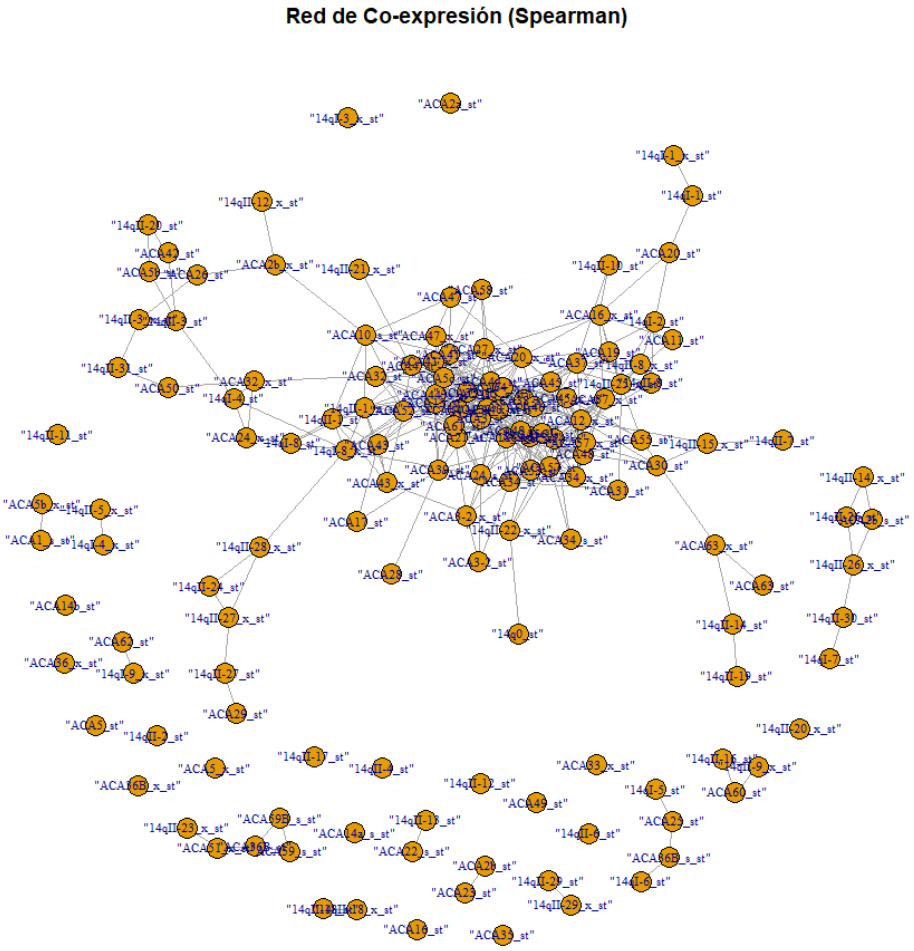
Spearman